DOXNET

24. FACHKONFERENZ UND AUSSTELLUNG

Dr.-Ing. Arthur Brack | 22. Juni 2022 | Baden-Baden

DOXNET® THE DOCUMENT X-PERTS NETWORK

Nächste Evolutionsstufe von Dokumenten mit „Semantic-Web“-Technologien

Dr.-Ing. Arthur Brack | 22. Juni 2022 | Baden-Baden

DOXNET®
THE DOCUMENT X-PERTS NETWORK

ZUR PERSON …



Dr.-Ing. Arthur Brack

Geschäftsführer der SET GmbH

Persönliche Angaben

- Über 20 Jahre Erfahrung in der Software-Entwicklung, davon 15 Jahre in der SET GmbH
- Promotion im Bereich „maschinenlesbare Forschungspapiere“ mit Semantic-Web- und KI-Technologien
- Honorardozent an der FHDW Hannover zu „Data Analytics“

Ziele des Vortrags

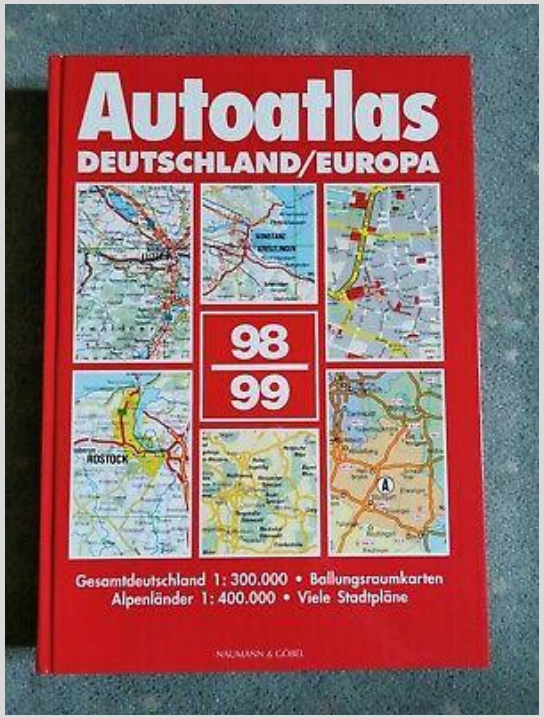
- Semantic-Web-Technologien kennenlernen
- Mögliche Mehrwerte dieser Technologien im Bereich von Geschäftsdokumenten erkennen
- Impulse für unsere Branche erhalten, um gemeinsam die nächste Generation von Geschäftsdokumenten zu gestalten

AGENDA

1. Motivation
2. Einführung in Semantic-Web-Technologien
3. Anwendungen von Semantic-Web-Technologien
4. Maschinenlesbare Geschäftsdokumente
5. Herausforderungen und Lösungsansätze
6. Fazit

Motivation

- Evolution von Straßenkarten …





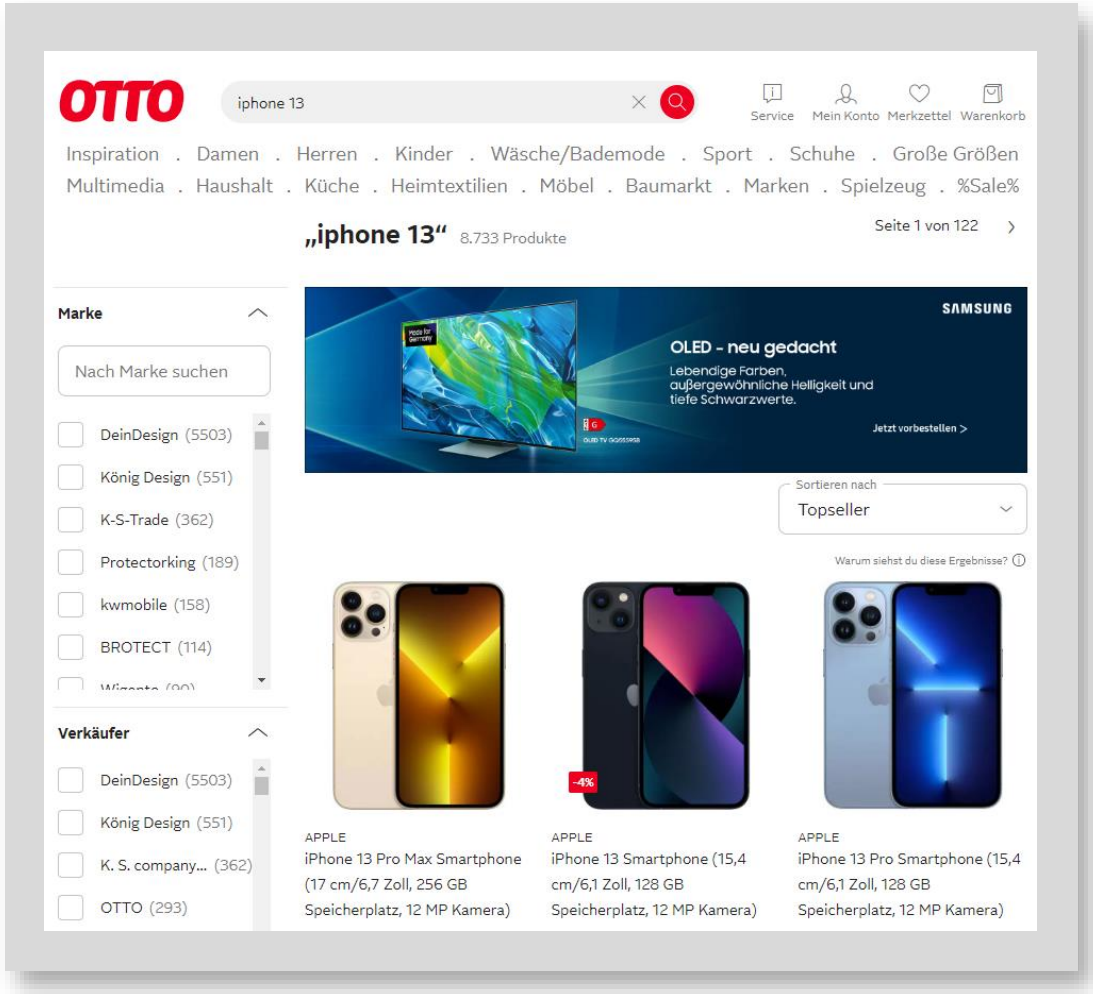
https://www.alpine.de

Kartendaten sind nun menschen- und maschinenlesbar!

Motivation

- Evolution von Produktkatalogen …

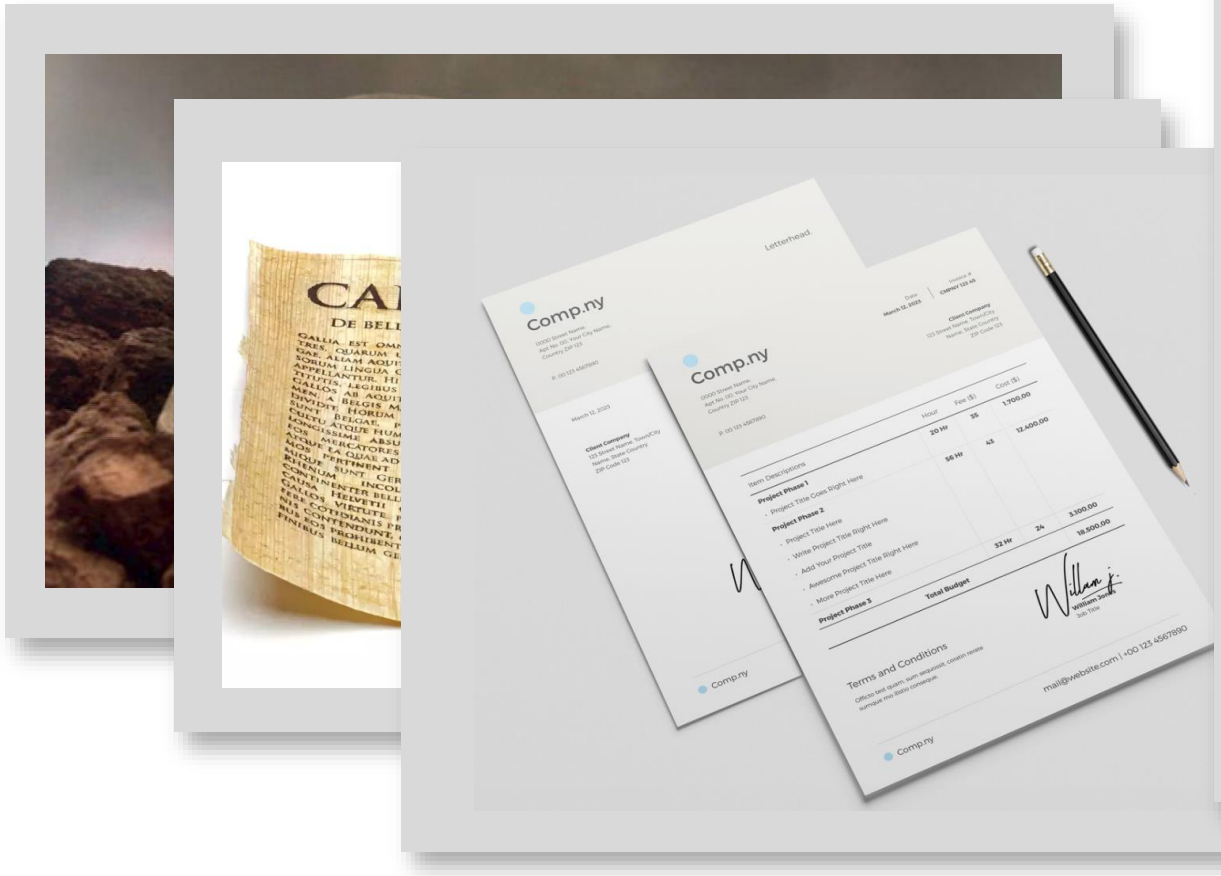


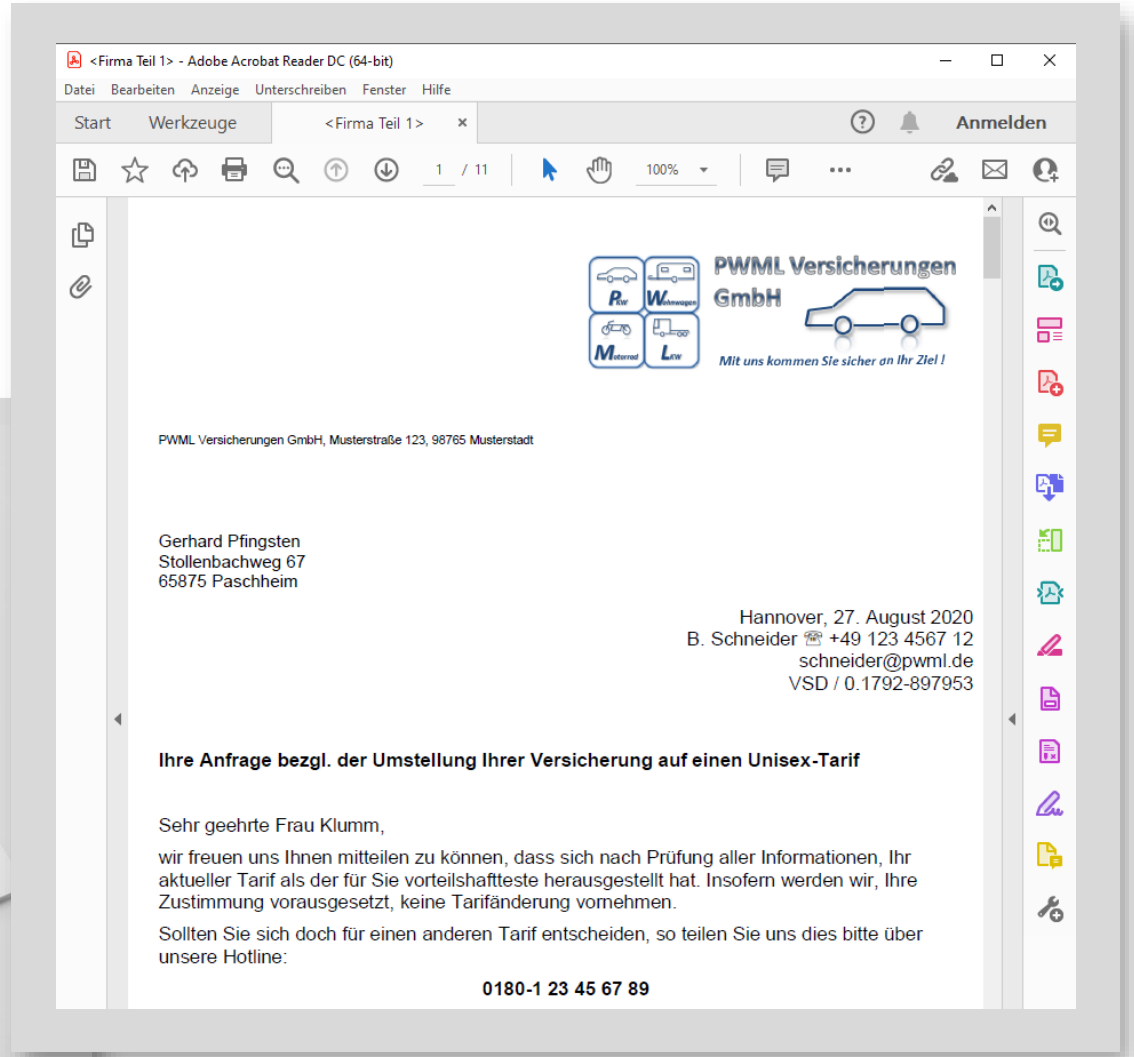


Produktdaten sind nun menschen- und maschinenlesbar!

Motivation

- Evolution von Geschäftsdokumenten …

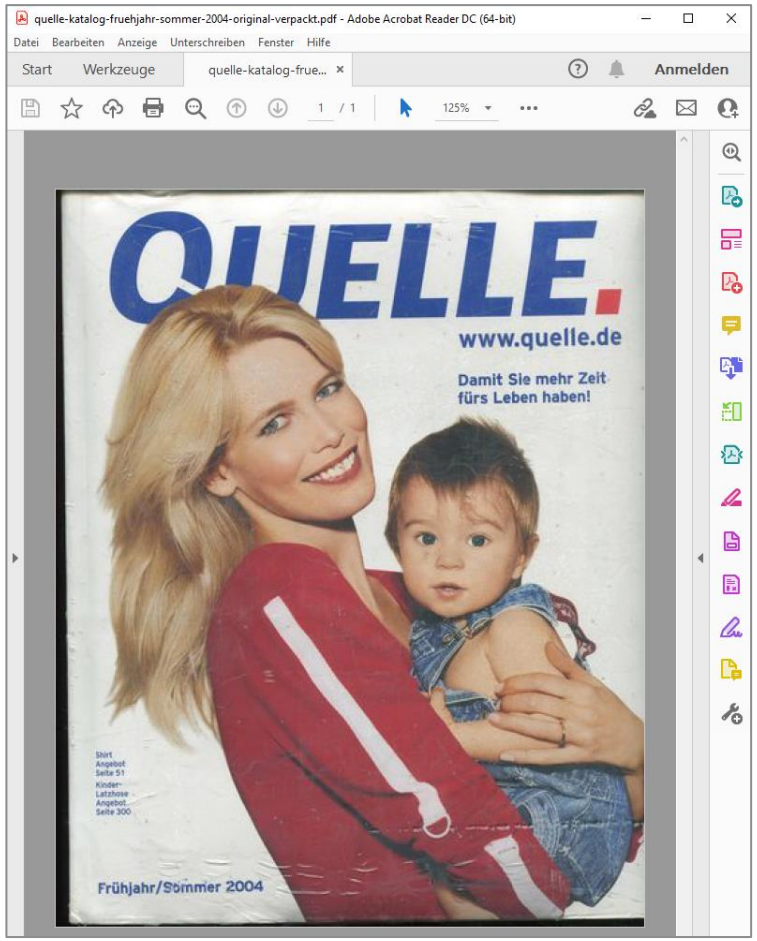


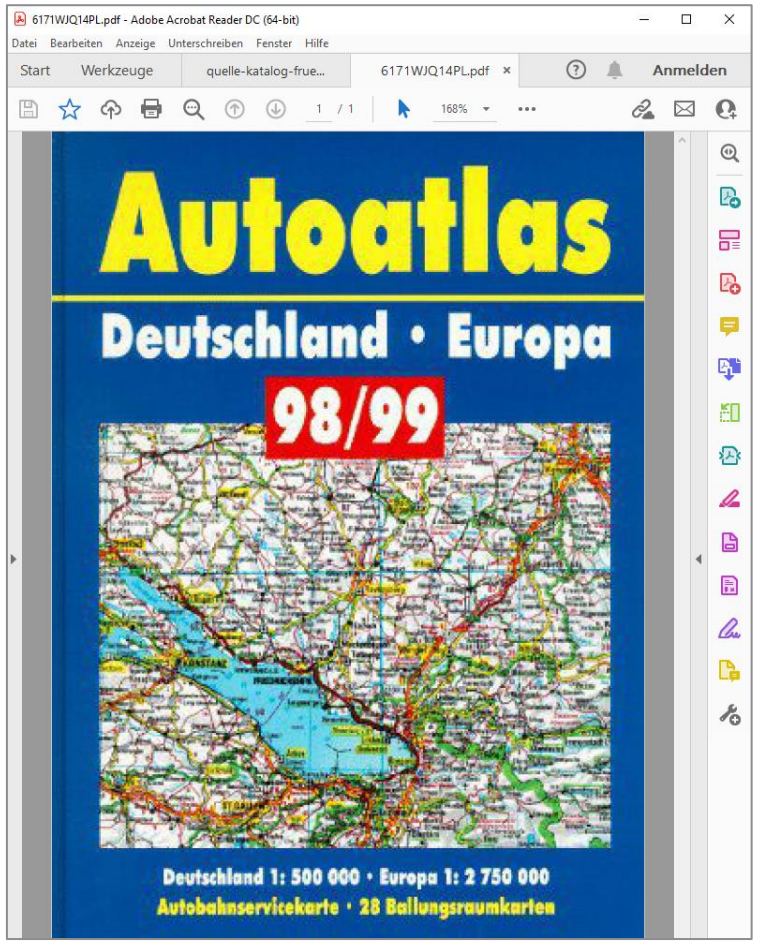


Geschäftsdokumente sind menschenlesbar, jedoch nach wie vor nicht maschinenlesbar!

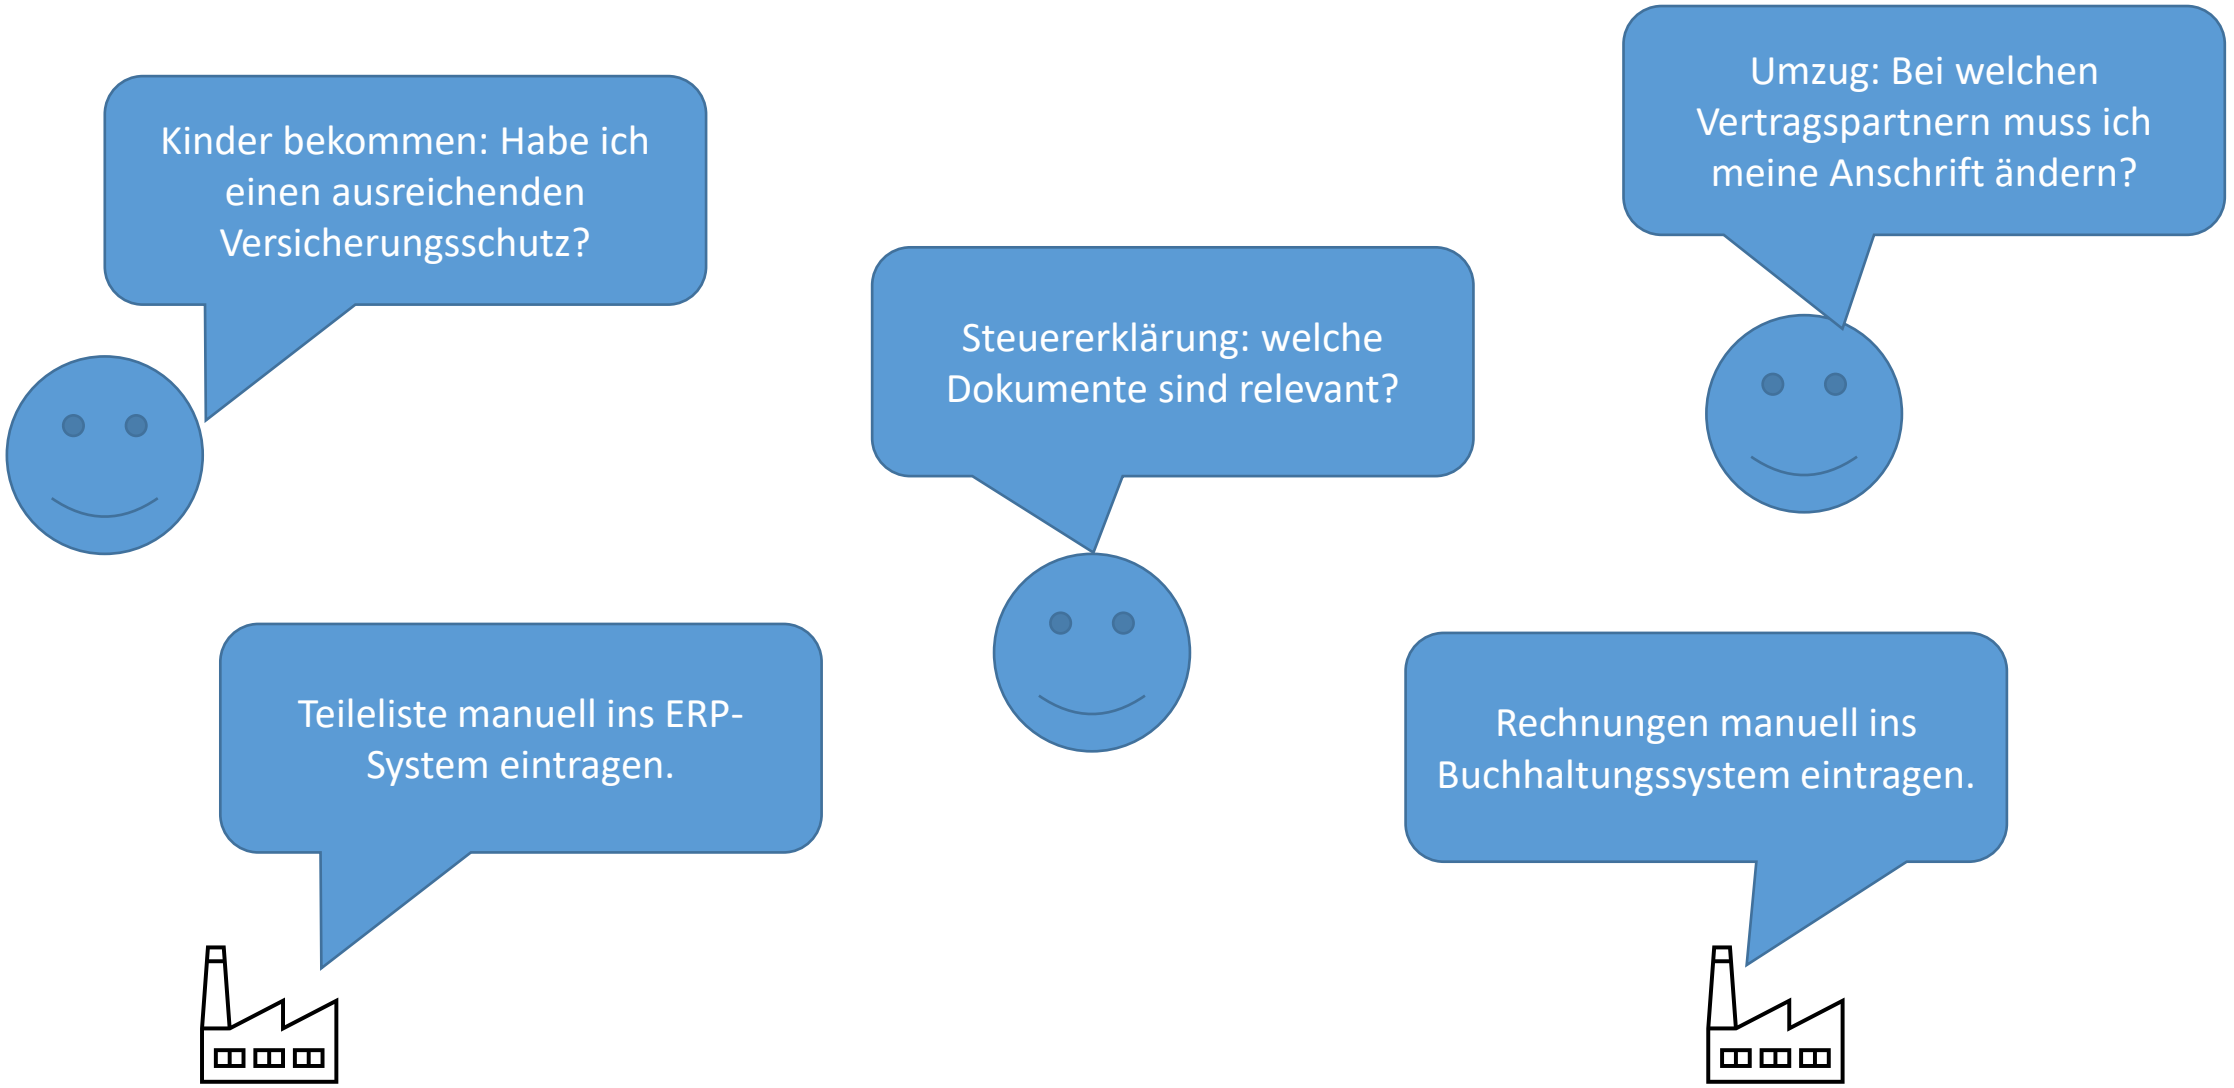
Motivation

- Der Digitalisierungsgrad von Geschäftsdokumenten entspricht Produktkatalogen und Straßenkarten im PDF-Format...





Motivation


Kinder bekommen: Habe ich einen ausreichenden Versicherungsschutz?
Steuererklärung: welche Dokumente sind relevant?
Umzug: Bei welchen Vertragspartnern muss ich meine Anschrift ändern?
Teileliste manuell ins ERP-System eintragen.
Rechnungen manuell ins Buchhaltungssystem eintragen.

Motivation

- Ursachen der Probleme
  1. Dokumente liegen beim Empfänger zum großen Teil physisch vor
  2. Inhalte der Dokumente sind kaum maschinenlesbar
  3. Dokumente und Objekte sind nicht miteinander verknüpft
  4. Fehlende Anwendungen, die Endanwender zufriedenstellend unterstützen können

Fokus dieses Vortrags

- Vision: menschen- **und** maschinenlesbare Geschäftsdokumente!



+



AGENDA

1. Motivation
2. Einführung in Semantic-Web-Technologien
3. Anwendungen von Semantic-Web-Technologien
4. Maschinenlesbare Geschäftsdokumente
5. Herausforderungen und Lösungsansätze
6. Fazit

Einführung in Semantic-Web-Technologien

Was bedeutet eigentlich Maschinenlesbarkeit?

Was sieht man auf dem PDF-Dokument rechts?

Ich sehe eine Rechnung über 240 EUR der Firma Company …



Ich sehe Buchstaben, Ziffern, Linien, Grafiken …



RECHNUNG

COMPANY

Rechnung an:

Muster Kunde
Musterstraße 2
1010 Wien

Rechnungsnummer: 2021-0018
Rechnungsdatum: 05.05.2021
Fälligkeitsdatum: 20.05.2021

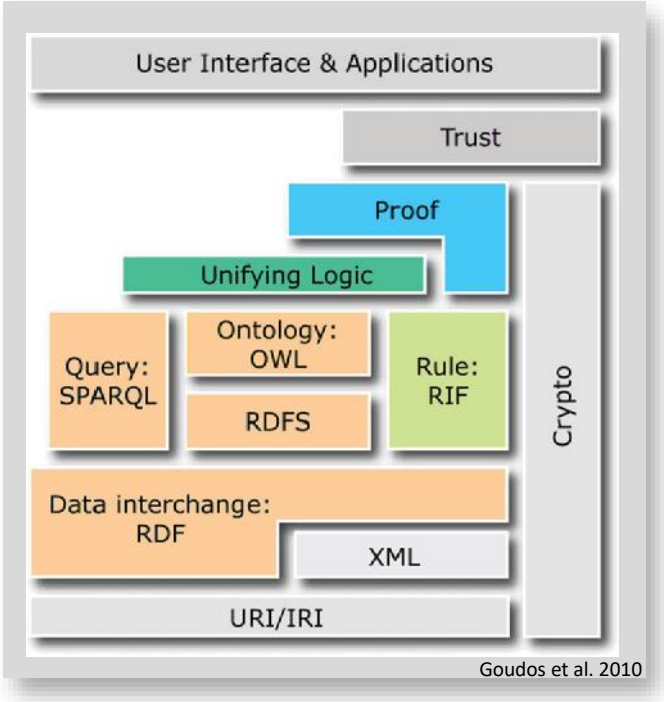
Anzahl	Beschreibung	Preis	Gesamtbetrag
2	Beratungsstunden	100,00	200,00
Leistungszeitraum: 01.05.2021 - 05.05.2021			
		Zwischensumme	€ 200,00
		20,00% MwSt. von € 200,00	€ 40,00
		Gesamtbetrag	**€ 240,00**

https://www.informer.eu

Einführung in Semantic-Web-Technologien

Semantic Web (aká Web 3.0)

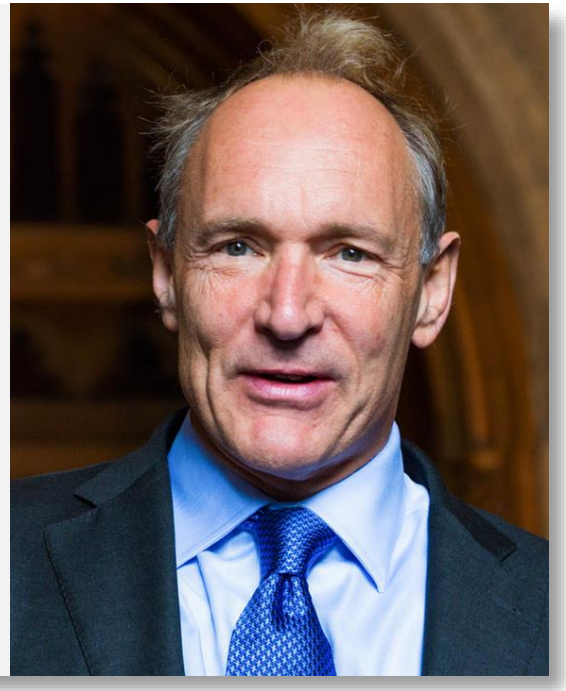
- Ziel : Internetdaten im World Wide Web (WWW) maschinenlesbar machen
- Erste Ideen und Technologien bereits im Jahr 1999 entstanden
- Technologien werden im World Wide Web Consortium (W3C) standardisiert



Goudos et al. 2010

"The Semantic Web is not a separate Web but an extension of the current one, in which information is given well-defined meaning, better enabling computers and people to work in cooperation."

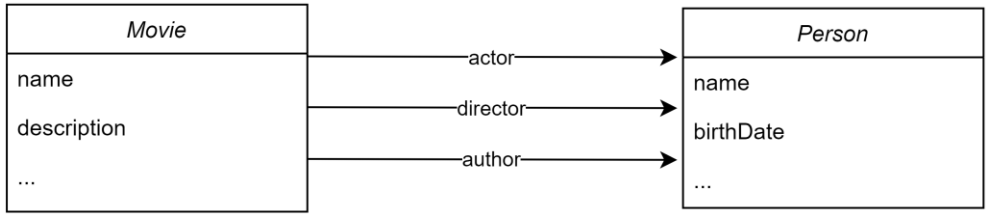
Tim Berners-Lee
- Begründer des WWW,
Vorsitzender vom W3C,
Professor am MIT -



Einführung in Semantic-Web-Technologien

Das Semantic Web besteht aus „Ontologien“ und „Instanzdaten“…

Auszug einer Ontologie (Modell) zur maschinenlesbaren Beschreibung von Filmen



Menschenlesbare Beschreibung eines Films

Pirates of the Carribean: On Stranger Tides (2011)
Jack Sparrow and Barbossa embark on a quest to find the elusive fountain of youth, only to discover that Blackbeard and his daughter are after it too.

Director: Rob Marshall
Writers: Ted Elliott, Terry Rossio, and 7 more credits
Stars: Johnny Depp, Penelope Cruz, Ian McShane
8/10 stars from 200 users. Reviews: 50.

Maschinenlesbare Beschreibung eines Films (Instanzdaten)

@type	Movie
name	Pirates of the Carribean: On Stranger Tides (2011)
director	
@type	Person
name	Rob Marshall
description	Jack Sparrow and Barbossa embark on a quest to find the elusive fountain of youth, only to discover that Blackbeard and his daughter are after it too.
author	
@type	Person
name	Terry Rossio
author	
@type	Person
name	Ted Elliott

https://schema.org

Einführung in Semantic-Web-Technologien

Maschinenlesbare Beschreibung von Instanzdaten kann in diversen Formaten erfolgen

RDF

```
<rdf:RDF xmlns:rdf="http://www.w3.org/1999/02/22-rdf-syntax-ns#"
         xmlns:schema="http://schema.org/">

 <schema:Movie rdf:nodeID="genid1">
   <schema:description rdf:datatype="http://www.w3.org/2001/XMLSchema#string">
     Jack Sparrow and Barbossa embark on a quest to find the elusive fountain of youth, only to discover
   </schema:description>
   <schema:name rdf:datatype="http://www.w3.org/2001/XMLSchema#string">
     Pirates of the Carribean: On Stranger Tides (2011)
   </schema:name>

   <schema:director>
     <schema:Person>
       <schema:name rdf:datatype="http://www.w3.org/2001/XMLSchema#string">Rob Marshall</schema:name>
     </schema:Person>
   </schema:director>

   <schema:author>
     <schema:Person>
       <schema:name rdf:datatype="http://www.w3.org/2001/XMLSchema#string">Ted Elliott</schema:name>
     </schema:Person>
   </schema:author>

   <schema:author>
     <schema:Person>
       <schema:name rdf:datatype="http://www.w3.org/2001/XMLSchema#string">Terry Rossio</schema:name>
     </schema:Person>
   </schema:author>
```

RDFa

```
<div vocab="https://schema.org/" typeof="Movie">

<h1 property="name">Pirates of the Carribean: On
<span property="description">Jack Sparrow and Bar
 find the elusive fountain of youth, only to disc
 his daughter are after it too.</span>
Director:
 <div property="director" typeof="Person">
<span property="name">Rob Marshall</span>
</div>
Writers:
 <div property="author" typeof="Person">
<span property="name">Ted Elliott</span>
</div>
<div property="author" typeof="Person">
<span property="name">Terry Rossio</span>
</div>
```

JSON-LD

```
{
 "@context": "https://schema.org",
 "@type": "Movie",
 "name": "Pirates of the Carribean: On Stranger Tides
 (2011)",
 "description": "Jack Sparrow and Barbossa embark on a
 quest to find the elusive fountain of youth, only to
 discover that Blackbeard and his daughter are after it
 too.",
 "director": {
   "@type": "Person",
   "name": "Rob Marshall"
 },
 "author": [
   {
     "@type": "Person",
     "name": "Ted Elliott"
   },
   {
     "@type": "Person",
     "name": "Terry Rossio"
   }
 ],
```

Als XMP-Headersätze in PDF-Dokumenten geeignet

Als Metainformationen in HTML-Dokumenten geeignet

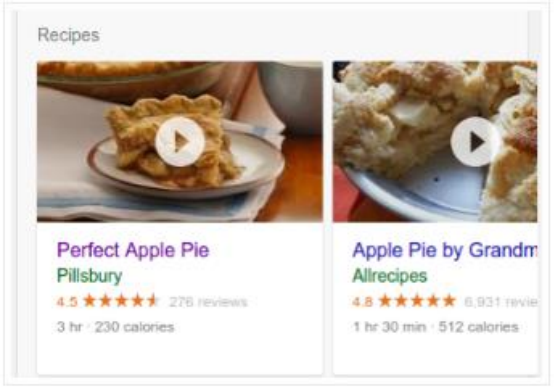
AGENDA

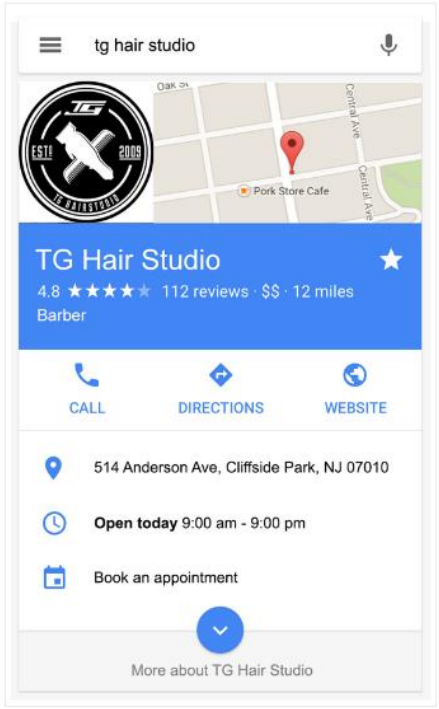
1. Motivation
2. Einführung in Semantic-Web-Technologien
3. Anwendungen von Semantic-Web-Technologien
4. Maschinenlesbare Geschäftsdokumente
5. Herausforderungen und Lösungsansätze
6. Fazit

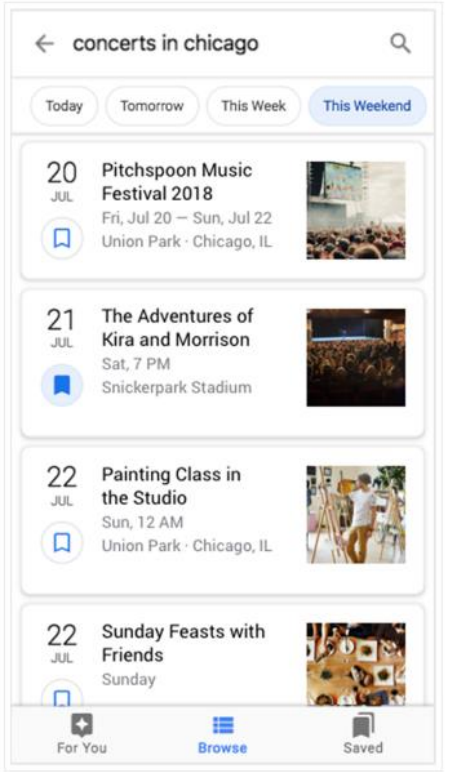
Anwendungen von Semantic-Web-Technologien

Besseres Sucherlebnis durch Schema.org

- Initiative aus 2011 durch Internet-Suchmaschinen (u. a. Google, Bing, Yahoo)
- Ziel: Ontologien zur Strukturierung von Informationen im Internet entwickeln: *„things, not strings“*
- Hauptanwendungsfall: Search Engine Optimization (SEO)





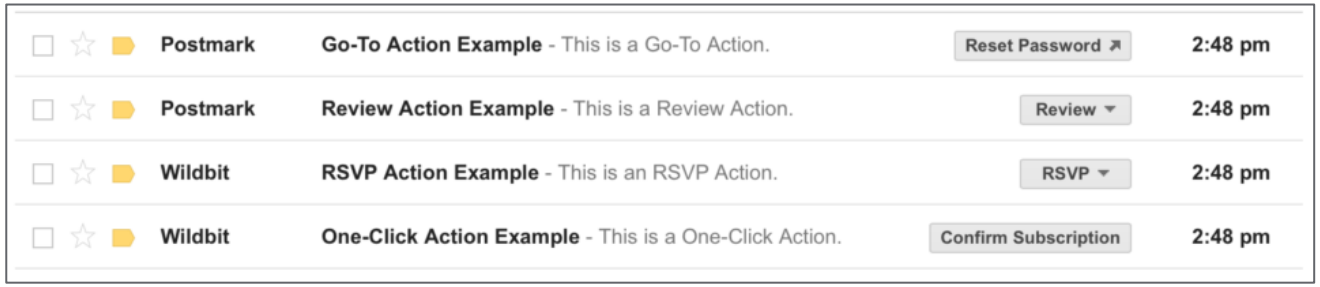


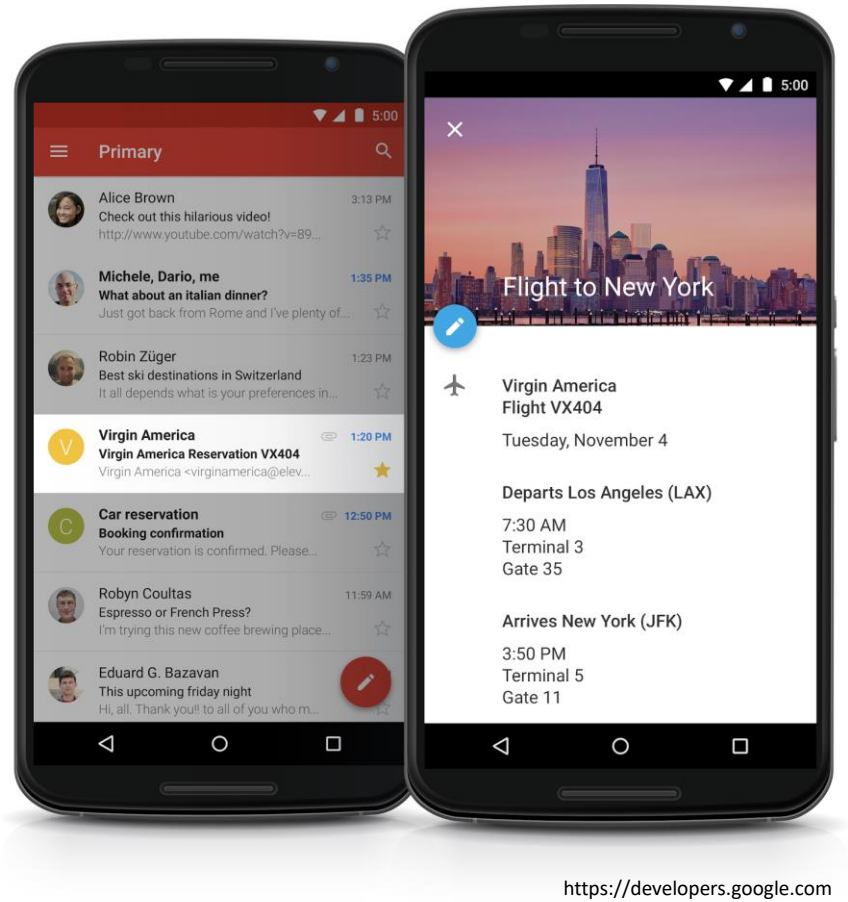
https://developers.google.com

Anwendungen von Semantic-Web-Technologien

Weiterer Anwendungsfall von Schema.org: Maschinenlesbare E-Mails…

- Häufig benutzte Entitätstypen in E-Mails
  - Bus reservation
  - Car rental reservation
  - Train reservation
  - Flight reservation
  - Order
  - Parcel delivery
  - Hotel reservation
  - Invoice
  - Restaurant reservation
  - Ticketed event reservation
- Aktionen in einer Email





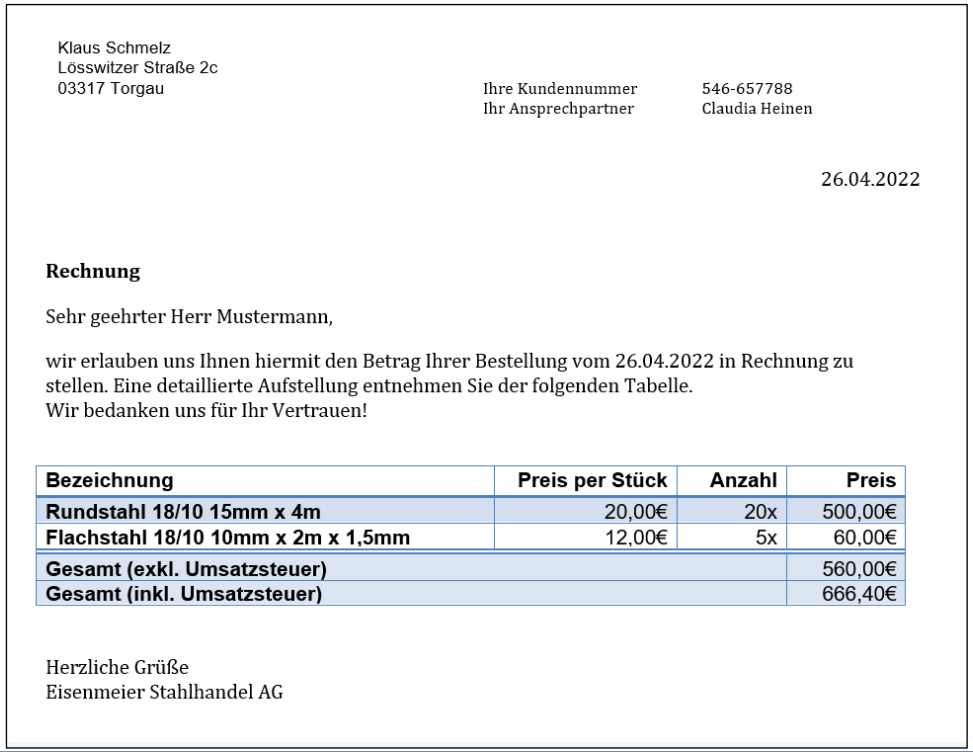
https://developers.google.com

Anwendungen von Semantic-Web-Technologien

ZUGFeRD: menschen- und maschinenlesbare Rechnungen

- Standard für hybride Rechnungen im digitalen Versand
- Basiert auf PDF/A und XRechnung-Format

Rechnung als PDF/A-Dokument



Klaus Schmelz
Lösswitzer Straße 2c
03317 Torgau

Ihre Kundennummer 546-657788
Ihr Ansprechpartner Claudia Heinen

26.04.2022

Rechnung

Sehr geehrter Herr Mustermann,

wir erlauben uns Ihnen hiermit den Betrag Ihrer Bestellung vom 26.04.2022 in Rechnung zu stellen. Eine detaillierte Aufstellung entnehmen Sie der folgenden Tabelle.
Wir bedanken uns für Ihr Vertrauen!

Bezeichnung	Preis per Stück	Anzahl	Preis
Rundstahl 18/10 15mm x 4m	20,00€	20x	500,00€
Flachstahl 18/10 10mm x 2m x 1,5mm	12,00€	5x	60,00€
Gesamt (exkl. Umsatzsteuer)			560,00€
Gesamt (inkl. Umsatzsteuer)			666,40€

Herzliche Grüße
Eisenmeier Stahlhandel AG

Eingebettetes XML (XRechnung)

```
<ram:Name>Rundstahl 18/10 15mm x 4m</ram:Name>
...
<ram:ChargeAmount>25.00</ram:ChargeAmount>
...
<ram:BilledQuantity unitCode="C62">20.0000</ram:BilledQuantity>
...
<ram:ApplicableTradeTax>
  <ram:TypeCode>VAT</ram:TypeCode>
  <ram:CategoryCode>S</ram:CategoryCode>
  <ram:RateApplicablePercent>19.00</ram:RateApplicablePercent>
</ram:ApplicableTradeTax>
...
<ram:LineTotalAmount>500.00</ram:LineTotalAmount>
...
<ram:LineTotalAmount>560.00</ram:LineTotalAmount>
<ram:TaxBasisTotalAmount>560.00</ram:TaxBasisTotalAmount>
<ram:TaxTotalAmount currencyID="EUR">106.40</ram:TaxTotalAmount>
<ram:GrandTotalAmount>666.40</ram:GrandTotalAmount>
<ram:DuePayableAmount>666.40</ram:DuePayableAmount>
```

Anwendungen von Semantic-Web-Technologien

Open Research Knowledge Graph (ORKG)

- Initiative der Technischen Informationsbibliothek (TIB) und Leibniz Universität Hannover
- Vision: maschinenlesbare Forschungspapiere

Properties	The early phase of the COVID-19 outbreak in Lombardy, Italy *2020 - Contribution 1*	Transmission potential of COVID-19 in Iran *2020 - Contribution 1*	Transmission potential of COVID-19 in Iran *2020 - Contribution 2*	Estimating the generation interval for COVID-19 based on symptom onset data *2020 - Contribution 1*
location	Lombardy, Italy	Iran	Iran	Singapore
Time period	Time interval	Time interval	Time interval	Time interval
has beginning	2020-01-14	2020-02-19	2020-02-19	2020-01-21
has end	2020-03-08	2020-02-29	2020-02-29	2020-02-26
Basic reproduction number	Basic reproduction number estimate value specification	Basic reproduction number estimate value specification	Basic reproduction number estimate value specification	Basic reproduction number estimate value specification
Has value	3.1	3.6	3.58	1.27
Confidence interval (95%)	Confidence interval (95%)	Confidence interval (95%)	Confidence interval (95%)	Confidence interval (95%)
Lower confidence limit	2.9	3.4	1.29	1.19
Upper confidence limit	3.2	4.2	8.46	1.36

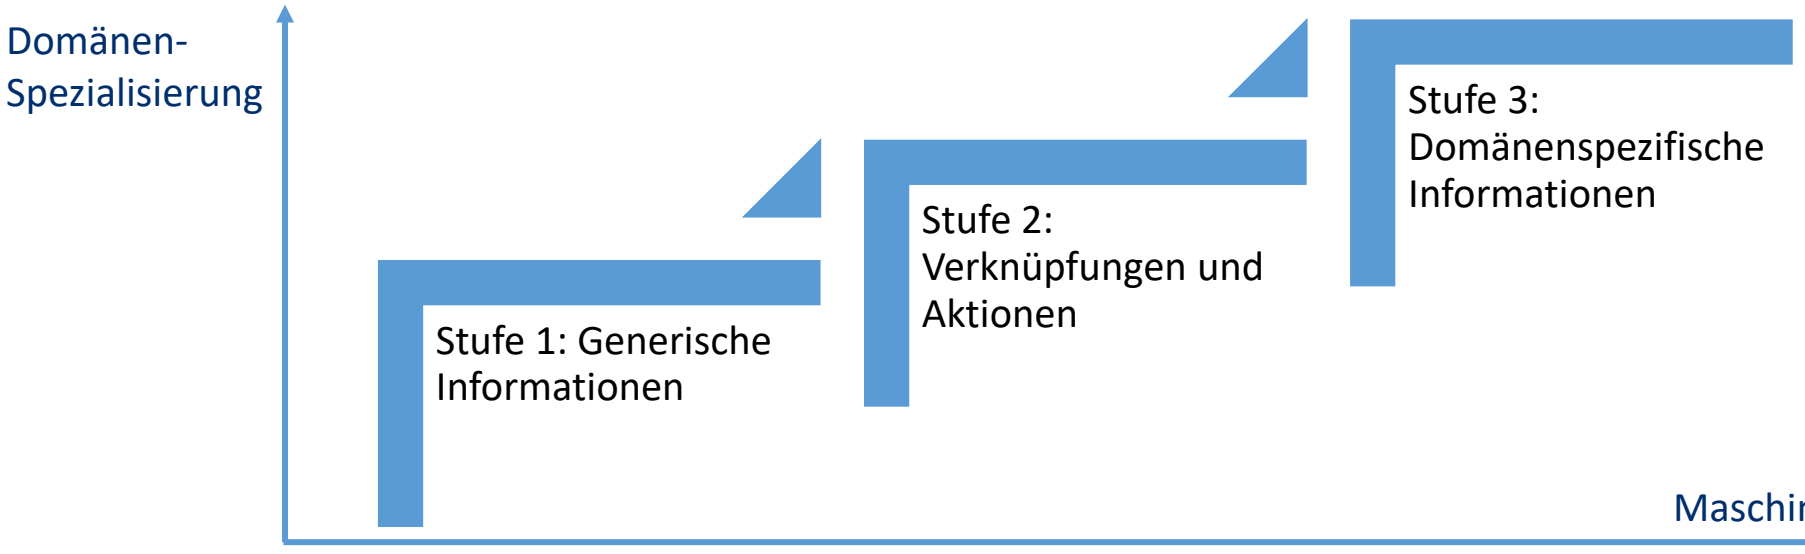
AGENDA

1	Motivation
2	Einführung in Semantic-Web-Technologien
3	Anwendungen von Semantic-Web-Technologien
4	Maschinenlesbare Geschäftsdokumente
5	Herausforderungen und Lösungsansätze
6	Fazit

Maschinenlesbare Geschäftsdokumente

- Maschinenlesbarkeit von Geschäftsdokumenten erfordert
  i. Entwicklung und Standardisierung passender Ontologien (generische vs. domänenspezifische Ontologien)
  ii. Hinterlegung der maschinenlesbaren Inhalte in Dokumenten (z. B. XMP-Header in PDF oder JSON-LD in HTML)

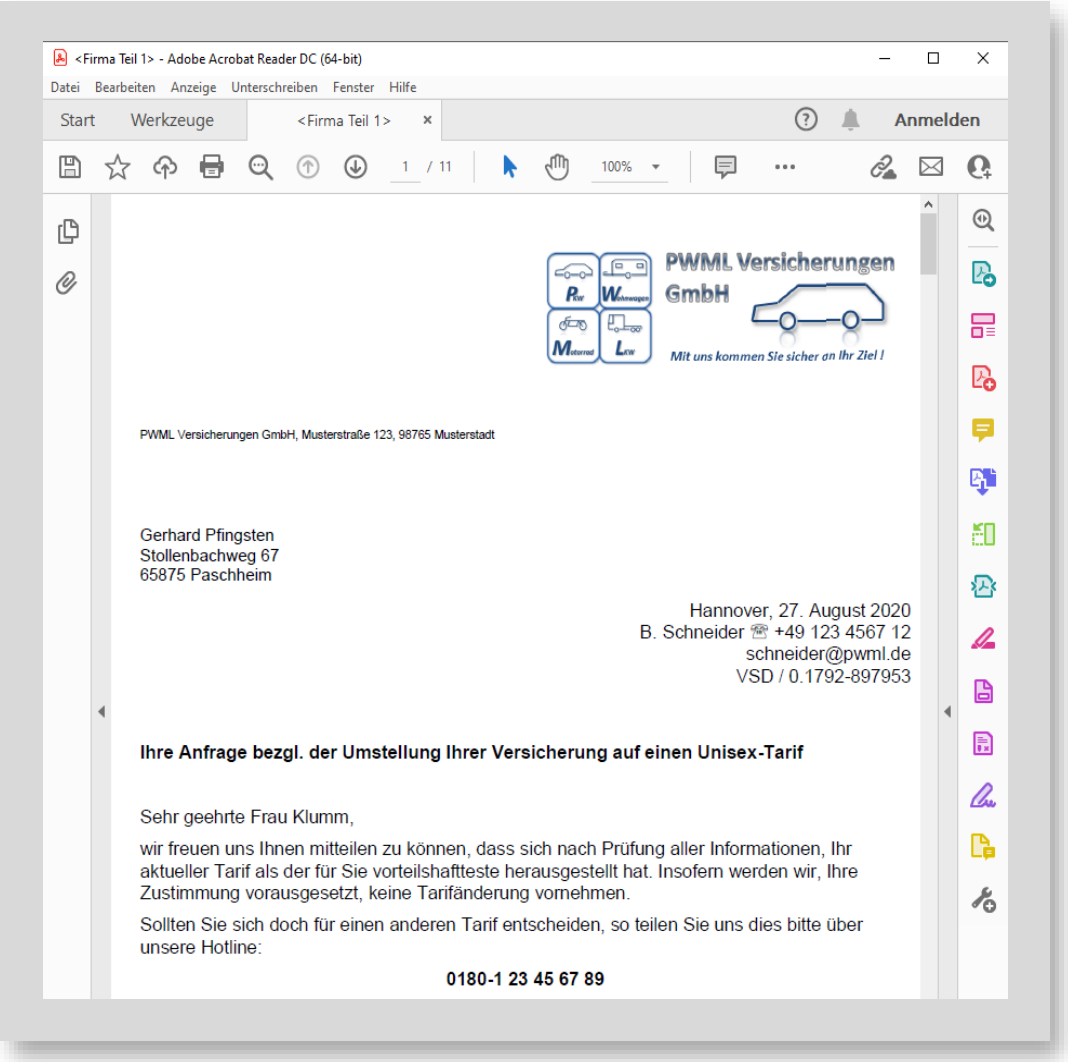
- Mögliche Evolutionsstufen von maschinenlesbaren Geschäftsdokumenten:



Maschinenlesbare Geschäftsdokumente

Stufe 1: Maschinenlesbarkeit von generischen Informationen

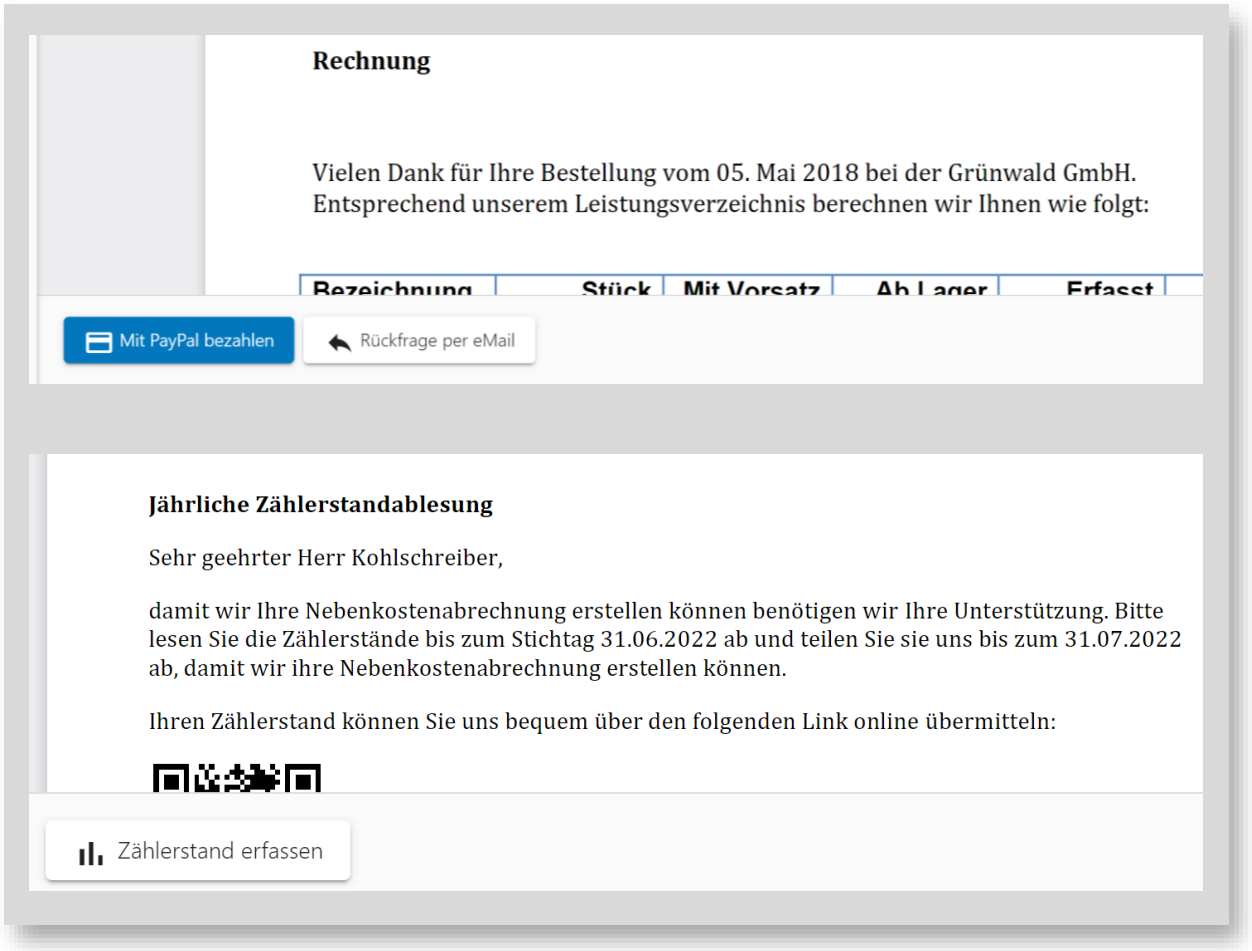
- Beispiele für generische Informationen
  - Termine / Fristen
  - Kontaktinformationen
  - Bankverbindungen
  - Vertragspartner
  - Kundennummer
  - Dokumententyp
  - …



Maschinenlesbare Geschäftsdokumente

Stufe 2: Verknüpfungen und Aktionen

- Beispiele für Verknüpfungen
  - Rechnung auf Vertragsdokument
  - Vertragsdokument auf AGB
  - Links auf Objekte (Produkt, Fahrzeug, Gebäude, usw.)
  - …
- Beispiele für Aktionen
  - Kontakt aufnehmen
  - Rechnung bezahlen
  - Zählerstand erfassen
  - Schaden melden
  - …



Maschinenlesbare Geschäftsdokumente

Stufe 3: Domänenspezifische Informationen

KFZ-Versicherung	KFZ-Leasingvertrag	Hypothekendarlehen	Rechnung	Handy-Vertrag	…
• Fahrzeugdaten • Laufleistung • Voll- / Teilkasko • …	• Fahrzeugdaten • Laufleistung • Leasingrate • …	• Gebäude • Darlehenssumme • Tilgung • Laufzeit • …	• Empfänger • Bankverbindung • Posten • …	• Smartphone • Tarif • Volumen • …	• …

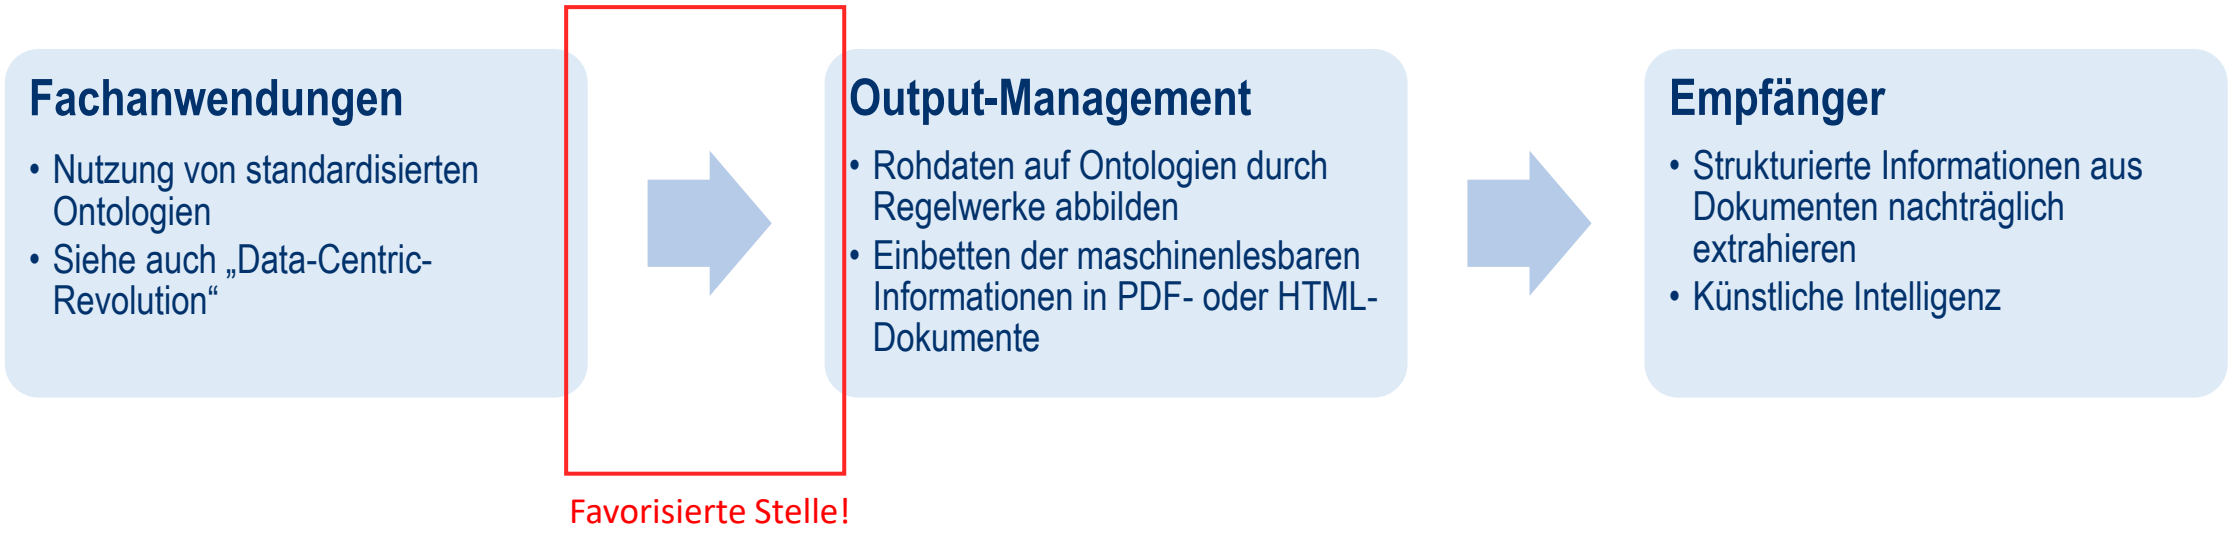
AGENDA

1	Motivation
2	Einführung in Semantic-Web-Technologien
3	Anwendungen von Semantic-Web-Technologien
4	Maschinenlesbare Geschäftsdokumente
5	Herausforderungen und Lösungsansätze
6	Fazit

Herausforderungen und Lösungsansätze

Wie können in der Praxis Dokumente um maschinenlesbare Informationen angereichert werden?

Dokumente können an verschiedenen Stellen mit maschinenlesbaren Informationen angereichert werden:



Herausforderungen und Lösungsansätze

Wie entwickeln wir gemeinsam standardisierte Ontologien?

- Bestehende Ontologien/Vokabulare wiederverwenden, z. B.:
  - Schema.org
  - XRechnung
  - Universal Business Language (UBL)
  - Free Insurance Data Initiative (FRIDA)
- Stufenweise Entwicklung neuer Ontologien:
  - Zusammenarbeit zwischen Versendern und Konsumenten von Dokumenten (DMS, Input-Management, Portale, Suchmaschinen, usw.)
  - Leichtgewichtige Prozesse nutzen wie bei schema.org, RFC, WikiData, …



Herausforderungen und Lösungsansätze

Was habe ich als versendendes Unternehmen davon?

- Für die Output-Management-Abteilung erstmal kein direkter Nutzen
- ABER: Seien Sie Innovationstreiber und schaffen Sie Mehrwerte für Unternehmen und unsere Gesellschaft!
    - Einfachere und effizientere B2B- und B2C-Kommunikation
    - Zufriedenere Kunden (Wettbewerbsvorteil)
    - Ermöglichung neuer Geschäftsfelder und Anwendungen
    - …
- Ethik – Enlightened Self-Interest:
    - *„Personen bzw. Organisationen, die im Interesse anderer handeln, dienen letztlich auch ihrem eigenen Interesse.“ (Wikipedia)*
    - Unternehmen mit gesellschaftlicher Verantwortung sind langfristig erfolgreicher! (→ Nachhaltigkeit)



AGENDA

1	Motivation
2	Einführung in Semantic-Web-Technologien
3	Anwendungen von Semantic-Web-Technologien
4	Maschinenlesbare Geschäftsdokumente
5	Herausforderungen und Lösungsansätze
6	Fazit

Fazit

- Geschäftsdokumente sind nach wie vor nur menschenlesbar, jedoch nicht maschinenlesbar
- Fehlende Maschinenlesbarkeit hat diverse Nachteile
    - Entwicklung nützlicher Anwendungen für Endkunden und Unternehmen wird erschwert
    - Ineffiziente B2C- und B2B-Kommunikation
- Semantic-Web-Technologien ermöglichen Maschinenlesbarkeit von Geschäftsdokumenten

- ***Lassen Sie uns gemeinsam als Document-X-perts die nächste Generation von Geschäftsdokumenten gestalten!***

Vielen Dank

Dr.-Ing. Arthur Brack
Geschäftsführer

SET GmbH
Rühmkorffstraße 5
30163 Hannover

E-Mail: arthur.brack@set.de

Internet: www.set.de

LinkedIn: https://de.linkedin.com/in/arthur-brack



DOXNET®
THE DOCUMENT X-PERTS NETWORK

KONTAKT & WEITERE INFORMATIONEN

Wir freuen uns
über Ihr Interesse

The Document X-perts Network e.V.

Mühlgrabenstraße 6
35578 Wetzlar
Germany

http://www.doxnet.de